Configuración
Actividad 1 — Variables Dicotómicas y Multiclase
Actividad 2 — Train/Test Split
Actividades 3 y 4
Actividades 5 y 6
Actividades 7 y 8
Actividades 11 y 12

Lab 7 – Regresión Logística

2026-04-20

Configuración

Actividad 1 — Variables Dicotómicas y Multiclase

Carga del dataset

```
## Dataset cargado: 171748 filas, 80 columnas
```

Limpieza de la variable `price`

`price` viene como texto con formato `"$97.00"`. Se elimina el símbolo `$` y las comas, y se convierte a numérico.

```
## Clase original de price: character
```

```
## Ejemplos originales: $97.00 $160.00 $38.00 $145.00 $58.00
```

```
##
## NAs en price_num tras conversión: 95502 (55.61%)
```

```
## Filas tras eliminar NAs y precios en 0: 76246
```

```
## Filas eliminadas: 95502
```

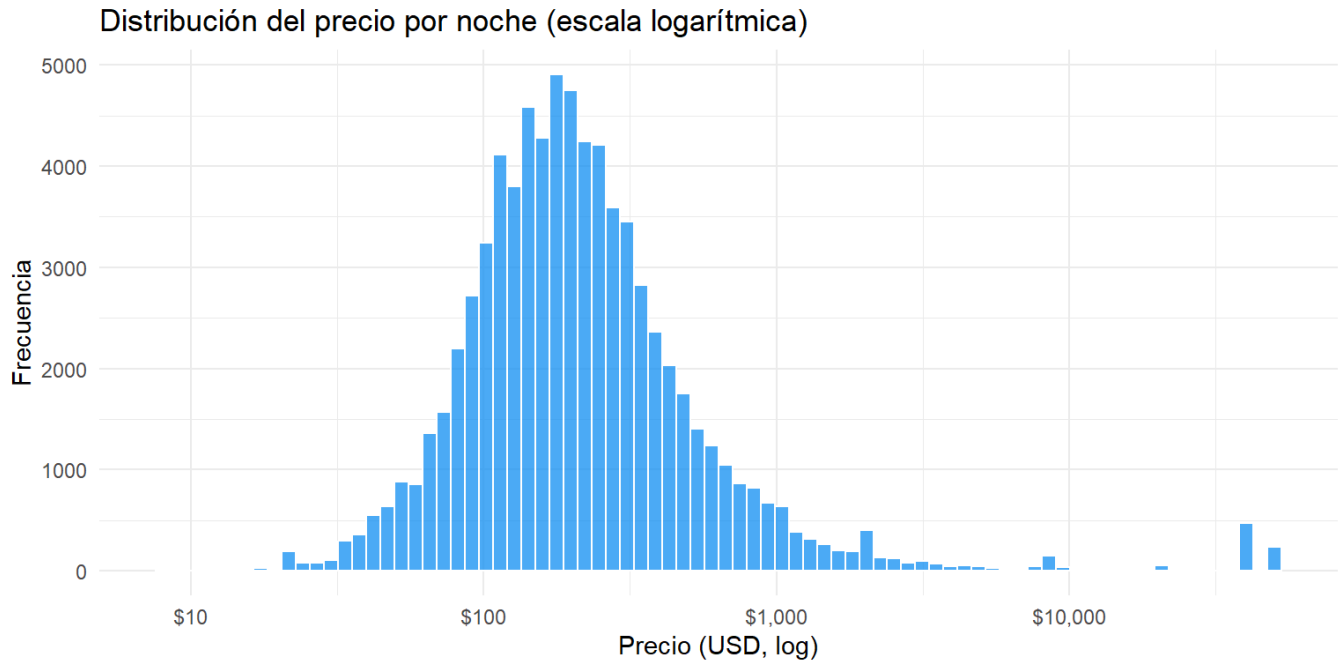

Cálculo de percentiles y creación de variables

Se usan percentiles 33 y 66 del precio como umbrales en lugar de valores fijos de negocio, porque:

1. **Garantizan clases balanceadas** en la variable objetivo, lo que es esencial para entrenar un modelo logístico sin sesgo hacia la clase mayoritaria.
2. **Son robustos al skew** del precio, que es fuertemente asimétrico a la derecha (hay propiedades muy caras que distorsionarían umbrales fijos).
3. **Son reproducibles**: dado el mismo dataset, producen exactamente los mismos cortes.

```
## Percentil 33 (umbral bajo/medio): $141
```

```
## Percentil 66 (umbral medio/caro): $264
```

Verificación de balance de clases

Balance de la variable binaria
es_caro

Clase	N	Proporción
No caro	50349	0.6603
Caro	25897	0.3397

Balance de la variable multiclase
categoria_precio

Categoría	N	Proporción

Categoría	N	Proporción
economico	25185	0.3303
medio	25164	0.3300
caro	25897	0.3397

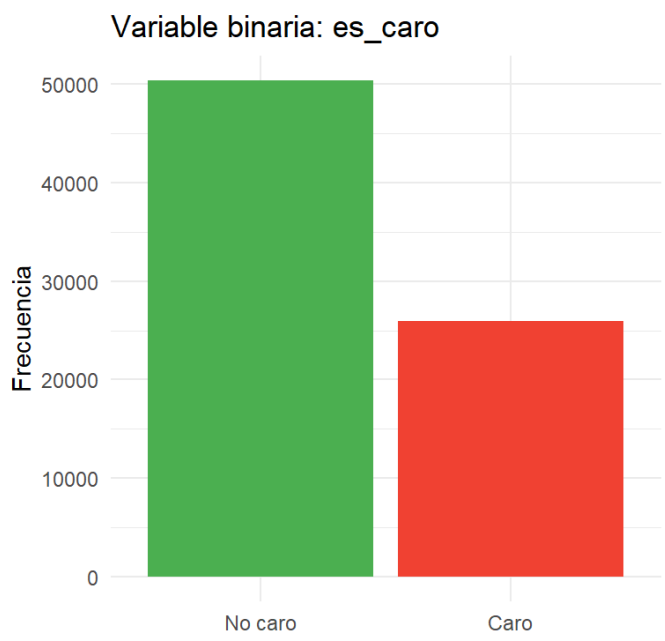

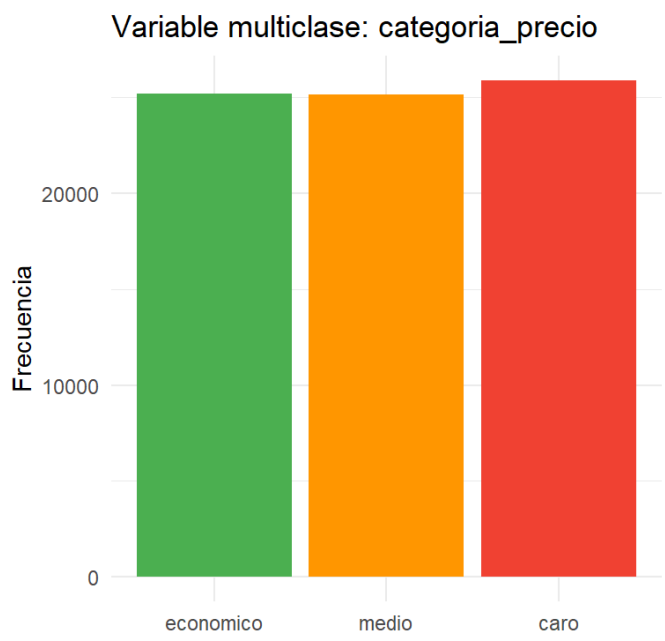

Actividad 2 — Train/Test Split

Justificación de la proporción 75/25

Se usa una división **75% train / 25% test** porque:

- Con ~170K filas, el conjunto de prueba (~42K) es suficientemente grande para obtener estimaciones robustas de las métricas sin desperdiciar datos de entrenamiento.
- La proporción 80/20 también es válida, pero 75/25 da un poco más de poder estadístico en la evaluación del test.
- Se usa **división estratificada** (`createDataPartition`) para que la proporción de clases sea la misma en train y test, evitando distribuciones desiguales por azar.

Split estratificado

Se implementa el muestreo estratificado manualmente: se toma el 75% de cada clase por separado y luego se unen, garantizando que la proporción de `es_caro` sea idéntica en train y test.

```
## Train: 57183 filas, 83 columnas
```

```
## Test:  19063 filas, 83 columnas
```

```
## Proporción train: 0.75
```

Verificación del balance en ambos conjuntos

Balance de clases en Train y Test

Conjunto	Clase	N	Proporción
Train	No caro	37761	0.6604
Train	Caro	19422	0.3396
Test	No caro	12588	0.6603
Test	Caro	6475	0.3397

Balance de categoría_precio en Train y Test

Conjunto	Categoría	N	Proporción
Train	economico	18804	0.3288
Train	medio	18957	0.3315
Train	caro	19422	0.3396
Test	economico	6381	0.3347
Test	medio	6207	0.3256
Test	caro	6475	0.3397

Exportación del split

Seed global: 42 — todos los integrantes deben usar `set.seed(42)`.

Percentil 33: $141 | **Percentil 66:** $264

Actividades 3 y 4

Actividad 3 — Modelo Logístico Binario con Validación Cruzada

Carga de `splits.RData`

```
## Splits cargados correctamente.
```

```
## Train: 57183 filas / 83 columnas
```

```
## Test:  19063 filas / 83 columnas
```

```
## Seed global recibido: 42
```

Selección de variables predictoras con criterio

Se aplica el siguiente criterio para elegir predictores:

1. Excluir variables objetivo y variables directamente derivadas de `price` para evitar fuga de información.
2. Excluir posibles identificadores (`id` , `*_id` , etc.) porque no tienen valor predictivo generalizable.
3. Excluir variables con más de 30% de valores faltantes.
4. Excluir variables con varianza casi nula.
5. Mantener variables numéricas para facilitar interpretación y diagnóstico de multicolinealidad con VIF.

```
## Número de predictores seleccionados: 38
```

```
## Predictores seleccionados:
```

```
##  [1] "host_listings_count"
##  [2] "host_total_listings_count"
##  [3] "latitude"
##  [4] "longitude"
##  [5] "accommodates"
##  [6] "bathrooms"
##  [7] "bedrooms"
##  [8] "beds"
##  [9] "minimum_nights"
## [10] "maximum_nights"
## [11] "minimum_minimum_nights"
## [12] "maximum_minimum_nights"
## [13] "minimum_maximum_nights"
## [14] "maximum_maximum_nights"
## [15] "minimum_nights_avg_ntm"
## [16] "maximum_nights_avg_ntm"
## [17] "availability_30"
## [18] "availability_60"
## [19] "availability_90"
## [20] "availability_365"
## [21] "number_of_reviews"
## [22] "number_of_reviews_ltm"
## [23] "number_of_reviews_l30d"
## [24] "availability_eoy"
## [25] "number_of_reviews_ly"
## [26] "estimated_occupancy_l365d"
## [27] "estimated_revenue_l365d"
## [28] "review_scores_rating"
## [29] "review_scores_accuracy"
## [30] "review_scores_cleanliness"
## [31] "review_scores_checkin"
## [32] "review_scores_communication"
## [33] "review_scores_location"
## [34] "review_scores_value"
## [35] "calculated_host_listings_count"
## [36] "calculated_host_listings_count_entire_homes"
## [37] "calculated_host_listings_count_private_rooms"
## [38] "reviews_per_month"
```

Resumen de selección de predictores

Etapa del filtrado	N° variables
Candidatas iniciales	79
Sin variables tipo ID	76
Con <= 30% NA	74
Sin varianza casi nula	69
Predictoras finales (numéricas)	38

Entrenamiento del modelo logístico binario (`glm`)

```
## Filas utilizadas para entrenar glm (tras drop_na): 46828
```

```
## Modelo base entrenado correctamente.
```

Validación cruzada 10-fold (AUC)

```
## AUC promedio (CV 10-fold): 0.8188
```

Accuracy en train con umbral 0.5

```
## Accuracy en train (umbral 0.5): 0.4258
```

Resultados principales de la Actividad 3

Métrica	Valor
AUC promedio CV (10-fold)	0.8188
Accuracy train (umbral 0.5)	0.4258

Actividad 4 — Análisis del Modelo

Significancia estadística de coeficientes

Coeficientes del modelo logístico y su significancia

Término	Coef.	Std. Error	z-value	p-value	Sig.
(Intercept)	2.652270e+01	1.0944	2.423450e+01	0.0000	***
host_listings_count	5.000000e-03	0.0001	3.351000e+01	0.0000	***
host_total_listings_count	-3.100000e-03	0.0001	-3.984550e+01	0.0000	***
latitude	-4.134000e-01	0.0152	-2.723880e+01	0.0000	***
longitude	1.591000e-01	0.0036	4.361410e+01	0.0000	***
accommodates	3.715000e-01	0.0293	1.269640e+01	0.0000	***
bathrooms	1.979700e+00	0.0592	3.343530e+01	0.0000	***
bedrooms	1.185900e+00	0.0568	2.087240e+01	0.0000	***
beds	-3.832000e-01	0.0408	-9.385300e+00	0.0000	***

Término	Coef.	Std. Error	z-value	p-value	Sig.
minimum_nights	8.610000e-02	0.0048	1.804400e+01	0.0000	***
maximum_nights	1.450000e-02	0.0001	1.727032e+02	0.0000	***
minimum_minimum_nights	2.119000e-01	0.0092	2.297320e+01	0.0000	***
maximum_minimum_nights	3.890000e-02	0.0018	2.108380e+01	0.0000	***
minimum_maximum_nights	-3.210000e-02	0.0001	-3.795681e+02	0.0000	***
maximum_maximum_nights	0.000000e+00	0.0000	1.020600e+00	0.3074	ns
minimum_nights_avg_ntm	-2.453000e-01	0.0098	-2.499700e+01	0.0000	***
maximum_nights_avg_ntm	0.000000e+00	0.0000	-9.621000e-01	0.3360	ns
availability_30	3.900000e-02	0.0086	4.513600e+00	0.0000	***
availability_60	-3.920000e-02	0.0090	-4.358200e+00	0.0000	***
availability_90	2.890000e-02	0.0099	2.916800e+00	0.0035	**
availability_365	-5.900000e-03	0.0004	-1.549610e+01	0.0000	***
number_of_reviews	-2.530000e-02	0.0031	-8.061100e+00	0.0000	***
number_of_reviews_ltm	4.408445e+12	23313.3241	1.890955e+08	0.0000	***
number_of_reviews_l30d	-1.511309e+12	71332.8692	-2.118671e+07	0.0000	***
availability_eoy	-4.020000e-02	0.0071	-5.695400e+00	0.0000	***
number_of_reviews_ly	-9.717000e-01	0.0219	-4.427610e+01	0.0000	***
estimated_occupancy_l365d	-6.723190e+11	3422.6362	-1.964331e+08	0.0000	***
estimated_revenue_l365d	2.058757e+06	3.1303	6.576793e+05	0.0000	***
review_scores_rating	-3.907000e-01	0.1556	-2.512000e+00	0.0120	•
review_scores_accuracy	5.963000e-01	0.1175	5.075900e+00	0.0000	***
review_scores_cleanliness	1.786300e+00	0.1091	1.637700e+01	0.0000	***
review_scores_checkin	4.670000e-01	0.0982	4.755300e+00	0.0000	***
review_scores_communication	-3.347000e-01	0.1172	-2.855400e+00	0.0043	**
review_scores_location	2.899000e-01	0.1258	2.304900e+00	0.0212	•
review_scores_value	-1.352000e-01	0.1008	-1.340700e+00	0.1800	ns

Término	Coef.	Std. Error	z-value	p-value	Sig.
calculated_host_listings_count	-5.610000e-02	0.0065	-8.610000e+00	0.0000	***
calculated_host_listings_count_entire_homes	1.840000e-02	0.0065	2.823400e+00	0.0048	**
calculated_host_listings_count_private_rooms	1.470000e-01	0.0100	1.467310e+01	0.0000	***
reviews_per_month	3.623700e+00	0.2555	1.418180e+01	0.0000	***

Diagnóstico de multicolinealidad (VIF)

Diagnóstico de multicolinealidad (VIF)

Variable	VIF	¿VIF > 5?
number_of_reviews_ltm	83577.943	Sí
estimated_occupancy_l365d	64849.797	Sí
number_of_reviews_l30d	48902.155	Sí
estimated_revenue_l365d	3868.092	Sí
calculated_host_listings_count	589.524	Sí
calculated_host_listings_count_entire_homes	589.373	Sí
maximum_nights_avg_ntm	120.248	Sí
maximum_maximum_nights	120.244	Sí
availability_90	108.853	Sí
availability_eoy	68.030	Sí
availability_60	43.876	Sí
minimum_nights_avg_ntm	37.035	Sí
minimum_minimum_nights	31.835	Sí
latitude	16.173	Sí
longitude	15.486	Sí
availability_30	11.074	Sí
host_listings_count	10.565	Sí
minimum_nights	9.509	Sí
reviews_per_month	6.272	Sí

Variable	VIF	¿VIF > 5?
maximum_minimum_nights	6.117	Sí
number_of_reviews	5.816	Sí
host_total_listings_count	5.651	Sí
review_scores_rating	4.143	No
calculated_host_listings_count_private_rooms	3.438	No
accommodates	2.966	No
bedrooms	2.935	No
review_scores_value	2.634	No
beds	2.485	No
review_scores_accuracy	2.471	No
review_scores_communication	2.278	No
review_scores_cleanliness	2.146	No
availability_365	1.977	No
bathrooms	1.740	No
review_scores_checkin	1.675	No
minimum_maximum_nights	1.564	No
maximum_nights	1.488	No
review_scores_location	1.475	No
number_of_reviews_ly	1.280	No

```
## Variables con VIF > 5: number_of_reviews_ltm, estimated_occupancy_l365d, number_of_revie
ws_l30d, estimated_revenue_l365d, calculated_host_listings_count, calculated_host_listings_
count_entire_homes, maximum_nights_avg_ntm, maximum_maximum_nights, availability_90, availa
bility_eoy, availability_60, minimum_nights_avg_ntm, minimum_minimum_nights, latitude, long
itude, availability_30, host_listings_count, minimum_nights, reviews_per_month, maximum_min
imum_nights, number_of_reviews, host_total_listings_count
## Decisión: se mantienen temporalmente para no alterar la línea base; su posible eliminaci
ón se evaluará en selección de modelo (AIC/BIC) de la Entrega 2.
```

Odds ratios e interpretación en lenguaje de negocio

Odds ratios del modelo base

Término	Odds Ratio	IC 2.5%	IC 97.5%	p-value	¿Sig. 5%?
(Intercept)	3.30109e+11	3.864288e+10	2.819975e+12	0.0000	Sí
host_listings_count	1.00500e+00	1.004700e+00	1.005300e+00	0.0000	Sí
host_total_listings_count	9.96900e-01	9.968000e-01	9.971000e-01	0.0000	Sí
latitude	6.61400e-01	6.420000e-01	6.813000e-01	0.0000	Sí
longitude	1.17240e+00	1.164100e+00	1.180800e+00	0.0000	Sí
accommodates	1.44990e+00	1.369100e+00	1.535500e+00	0.0000	Sí
bathrooms	7.24040e+00	6.447100e+00	8.131400e+00	0.0000	Sí
bedrooms	3.27370e+00	2.928700e+00	3.659300e+00	0.0000	Sí
beds	6.81600e-01	6.292000e-01	7.384000e-01	0.0000	Sí
minimum_nights	1.08990e+00	1.079800e+00	1.100100e+00	0.0000	Sí
maximum_nights	1.01460e+00	1.014400e+00	1.014700e+00	0.0000	Sí
minimum_minimum_nights	1.23600e+00	1.213800e+00	1.258500e+00	0.0000	Sí
maximum_minimum_nights	1.03960e+00	1.035900e+00	1.043400e+00	0.0000	Sí
minimum_maximum_nights	9.68400e-01	9.683000e-01	9.686000e-01	0.0000	Sí
maximum_maximum_nights	1.00000e+00	1.000000e+00	1.000000e+00	0.3074	No
minimum_nights_avg_ntm	7.82400e-01	7.675000e-01	7.976000e-01	0.0000	Sí
maximum_nights_avg_ntm	1.00000e+00	1.000000e+00	1.000000e+00	0.3360	No
availability_30	1.03970e+00	1.022300e+00	1.057500e+00	0.0000	Sí
availability_60	9.61500e-01	9.447000e-01	9.786000e-01	0.0000	Sí
availability_90	1.02940e+00	1.009500e+00	1.049600e+00	0.0035	Sí
availability_365	9.94100e-01	9.934000e-01	9.949000e-01	0.0000	Sí
number_of_reviews	9.75100e-01	9.691000e-01	9.811000e-01	0.0000	Sí
number_of_reviews_ltm	Inf	Inf	Inf	0.0000	Sí
number_of_reviews_l30d	0.00000e+00	0.000000e+00	0.000000e+00	0.0000	Sí
availability_eoy	9.60600e-01	9.474000e-01	9.740000e-01	0.0000	Sí
number_of_reviews_ly	3.78400e-01	3.625000e-01	3.951000e-01	0.0000	Sí

Término	Odds Ratio	IC 2.5%	IC 97.5%	p-value	¿Sig. 5%?
estimated_occupancy_l365d	0.00000e+00	0.000000e+00	0.000000e+00	0.0000	Sí
estimated_revenue_l365d	Inf	Inf	Inf	0.0000	Sí
review_scores_rating	6.76600e-01	4.988000e-01	9.177000e-01	0.0120	Sí
review_scores_accuracy	1.81540e+00	1.442000e+00	2.285500e+00	0.0000	Sí
review_scores_cleanliness	5.96740e+00	4.818800e+00	7.389700e+00	0.0000	Sí
review_scores_checkin	1.59520e+00	1.315900e+00	1.933800e+00	0.0000	Sí
review_scores_communication	7.15600e-01	5.687000e-01	9.004000e-01	0.0043	Sí
review_scores_location	1.33630e+00	1.044300e+00	1.709800e+00	0.0212	Sí
review_scores_value	8.73500e-01	7.169000e-01	1.064400e+00	0.1800	No
calculated_host_listings_count	9.45400e-01	9.334000e-01	9.576000e-01	0.0000	Sí
calculated_host_listings_count_entire_homes	1.01850e+00	1.005600e+00	1.031600e+00	0.0048	Sí
calculated_host_listings_count_private_rooms	1.15840e+00	1.135800e+00	1.181300e+00	0.0000	Sí
reviews_per_month	3.74754e+01	2.271150e+01	6.183690e+01	0.0000	Sí

Interpretación de al menos 3 odds ratios (lenguaje de negocio):

- **host_total_listings_count**: manteniendo las demás variables constantes, un aumento de 1 unidad en esta variable reduce los odds de que la propiedad sea *cara* en aproximadamente 0.31% (OR = 0.997).
- **longitude**: manteniendo las demás variables constantes, un aumento de 1 unidad en esta variable incrementa los odds de que la propiedad sea *cara* en aproximadamente 17.24% (OR = 1.172).
- **maximum_nights**: manteniendo las demás variables constantes, un aumento de 1 unidad en esta variable incrementa los odds de que la propiedad sea *cara* en aproximadamente 1.46% (OR = 1.015).

Variables no significativas: decisión

```
##
## Decisión: se mantienen en el modelo base para preservar una referencia completa.
```

Exportacion del modelo base

Actividades 5 y 6

Actividad 5 — Evaluación en Test

Carga de prerequisitos

```
## train: 57183 filas / test: 19063 filas
```

```
## Predictores: 38
```

```
## AUC CV (referencia): 0.8188
```

Predicciones en test con umbral 0.5

```
## Filas de test usadas (tras drop_na): 15643
```

Métricas en test

Métricas del modelo base en el conjunto de test (umbral = 0.5)

Métrica	Valor
Accuracy	0.4277
Precision	0.3106
Recall (Sensitivity)	0.6993
F1-Score	0.4301
AUC-ROC	0.4887

Curva ROC

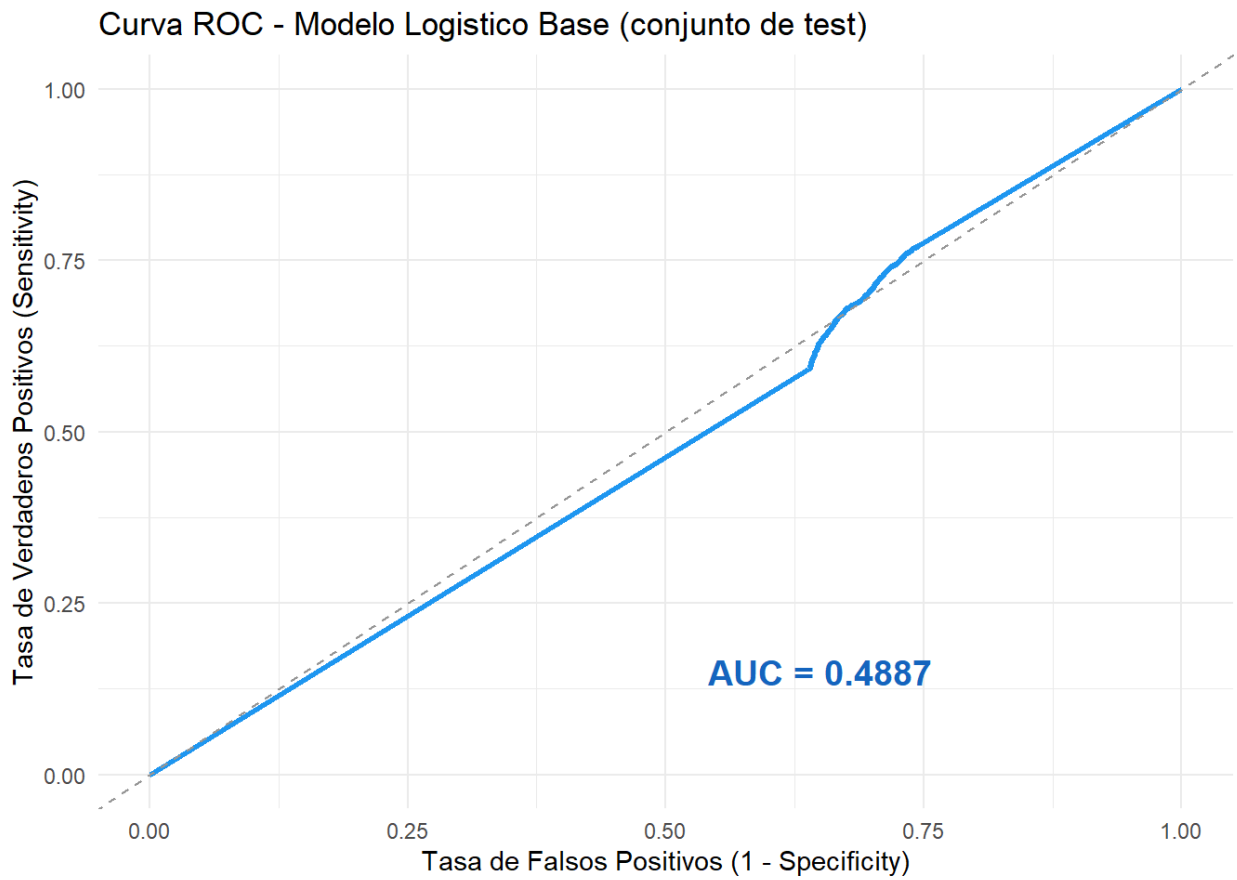

La curva ROC se aleja claramente de la diagonal (clasificador aleatorio), lo que indica que el modelo tiene capacidad discriminativa real. Un AUC cercano a 1 refleja que el modelo logra separar bien propiedades caras de las no caras.

Comparación AUC en CV vs AUC en test

Comparación AUC: validación cruzada vs conjunto de test

Evaluación	AUC	Δ AUC (CV − Test)
CV 10-fold (train)	0.8188	NA
Test set	0.4887	0.3301

> **Interpretación:** El AUC en CV supera al AUC en test por 0.3301 puntos. Esta brecha sugiere cierto grado de overfitting: el modelo se ajusta mejor a los datos de entrenamiento que a datos nuevos.

Actividad 6 — Overfitting y Curvas de Aprendizaje

Las curvas de aprendizaje miden cómo evoluciona el desempeño del modelo a medida que aumenta la cantidad de datos de entrenamiento disponibles. Se entrena el mismo modelo logístico con subconjuntos crecientes del `train_data` (del 10% al 100% en pasos del 10%) y se evalúa el accuracy tanto sobre ese subconjunto como sobre el `test_data` completo.

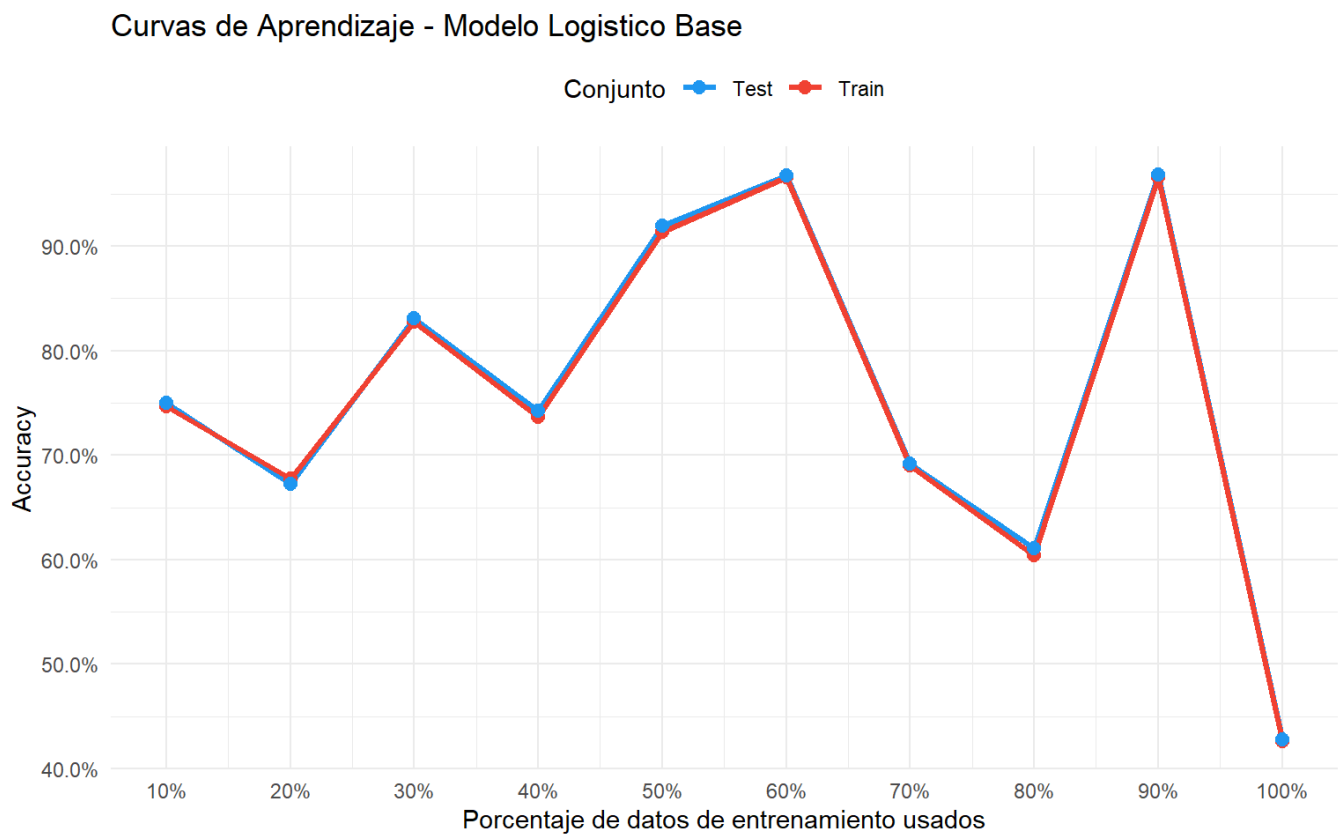

Accuracy en train al 100% de datos: 0.4258

Accuracy en test al 100% de datos: 0.4277

Gap train – test: -0.0018

> **Diagnóstico: Underfitting.** Ambas curvas convergen en valores de accuracy bajos. El modelo no captura suficiente información del problema. **Recomendación:** agregar variables más informativas o considerar modelos más flexibles.

Tabla de resultados por proporción

Evolución del accuracy por tamaño del subconjunto de entrenamiento

% datos train	N filas	Accuracy Train	Accuracy Test
10%	4682	0.7463	0.7504
20%	9365	0.6777	0.6724

% datos train	N filas	Accuracy Train	Accuracy Test
30%	14048	0.8276	0.8308
40%	18731	0.7365	0.7427
50%	23414	0.9136	0.9195
60%	28096	0.9656	0.9678
70%	32779	0.6899	0.6920
80%	37462	0.6039	0.6108
90%	42145	0.9662	0.9682
100%	46828	0.4258	0.4277

Exportación de objetos para Entrega 2

Actividades 7 y 8

Actividad 7 — Tuneo con Regularizacion

Preparacion de prerequisitos

```
## Filas train usadas en regularizacion: 46828
```

```
## Filas test usadas en regularizacion: 15643
```

```
## Numero de predictores: 38
```

Se utiliza `cv.glmnet` con validacion cruzada interna de 10 folds y `type.measure = "auc"`.
El lambda optimo de cada variante se toma como `lambda.min` (maximiza el AUC promedio de CV).

Entrenamiento de Lasso, Ridge y Elastic Net

Comparacion de AUC: modelo base vs modelos regularizados

Modelo	Alpha	Lambda optimo	AUC CV interno	AUC test
Base (sin regularizacion)	NA	NA	NA	0.4887
Lasso	1.0	0.0000	0.9945	0.9947
Ridge	0.0	0.0222	0.8812	0.8904

Modelo	Alpha	Lambda optimo	AUC CV interno	AUC test
Elastic Net	0.5	0.0000	0.9829	0.9838

```
## Mejor variante regularizada en test: Lasso
```

```
## AUC test del mejor modelo regularizado: 0.9947
```

```
## AUC test del modelo base: 0.4887
```

```
## Conclusion: la regularizacion mejora el modelo base en AUC de test.
```

Variables eliminadas por Lasso

Variables con coeficiente 0 en Lasso (lambda optimo)

variable_eliminada
number_of_reviews_l30d

Las variables que Lasso lleva a cero suelen ser predictores redundantes o de bajo aporte marginal una vez controladas las demas variables.
Si la eliminacion afecta variables con poca significancia estadistica o con alta correlacion con otras, la reduccion de complejidad es razonable desde el punto de vista de negocio y generalizacion.

Actividad 8 — Matriz de Confusion y Metricas Completas

Matriz de confusion - Modelo base (umbral 0.5)

Real	Predicho caro (1)	Predicho no caro (0)
Caro (1)	3379	1453
No caro (0)	7500	3311

Matriz de confusion - Modelo regularizado Lasso (umbral 0.5)

Real	Predicho caro (1)	Predicho no caro (0)
Caro (1)	4441	391
No caro (0)	220	10591

Comparacion de TP, TN, FP y FN: base vs regularizado

Modelo	TP	TN	FP	FN
Base	3379	3311	7500	1453
Regularizado (Lasso)	4441	10591	220	391

Metricas completas: base vs mejor modelo regularizado

Modelo	Accuracy	Sensitivity	Specificity	Precision	F1	AUC
Base	0.4277	0.6993	0.3063	0.3106	0.4301	0.4887
Regularizado (Lasso)	0.9609	0.9191	0.9797	0.9528	0.9356	0.9947

Error mas frecuente en modelo base: FP (falsos positivos)

Error mas frecuente en modelo regularizado: FN (falsos negativos)

En el contexto de SmartStay, suele ser mas costoso no detectar una propiedad realmente cara (FN), porque se pierde oportunidad de aplicar estrategias premium y capturar ingresos altos. Por ello, al comparar modelos conviene priorizar **Sensitivity/Recall** sin descuidar Precision para evitar una sobreclasificacion excesiva de propiedades no caras como caras.

Actividad 9 — Ajuste de Umbral con Indice de Youden

El umbral por defecto de 0.5 no necesariamente maximiza el desempeno del clasificador. El **indice de Youden** (J = Sensitivity + Specificity - 1) identifica el punto de la curva ROC que maximiza la suma de ambas tasas, ofreciendo el mejor balance entre deteccion de verdaderos positivos y rechazo de verdaderos negativos.

```
## Umbral optimo (Youden): 0.3539
```

```
## Sensitivity en ese umbral: 0.9613
```

```
## Specificity en ese umbral: 0.9562
```

Comparacion de umbrales: 0.5 vs optimo de Youden

Umbral	Accuracy	Sensitivity	Specificity	Precision	F1	AUC
0.50 (default)	0.9609	0.9191	0.9797	0.9528	0.9356	0.9947
0.3539 (Youden)	0.9577	0.9613	0.9562	0.9074	0.9336	0.9947

Matriz de confusion - Umbral 0.5 (Regularizado Lasso)

Real	Predicho caro (1)	Predicho no caro (0)

Real	Predicho caro (1)	Predicho no caro (0)
Caro (1)	4441	391
No caro (0)	220	10591

Matriz de confusion - Umbral Youden 0.3539 (Regularizado Lasso)

Real	Predicho caro (1)	Predicho no caro (0)
Caro (1)	4645	187
No caro (0)	474	10337

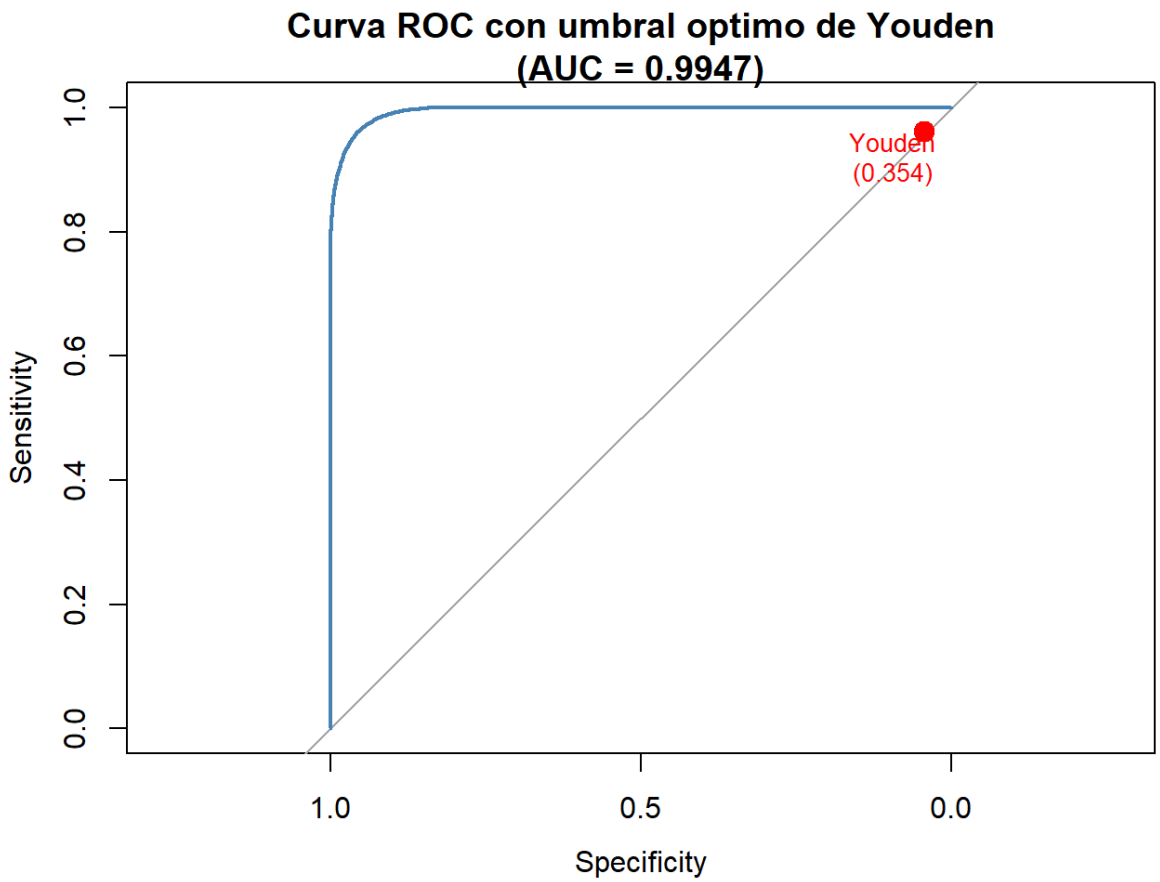

Cambio en Sensitivity: 0.0422

Cambio en Specificity: -0.0235

Cambio en F1: -0.0021

En SmartStay, reducir los falsos negativos (propiedades caras clasificadas como baratas) es prioritario porque implica perder oportunidades de estrategia premium. Si el umbral de Youden aumenta la Sensitivity a costa de algo de Specificity, la perdida de precision en las clasicas no-caras es tolerable: el negocio prefiere sobreclasificar ligeramente hacia “caro” antes que dejar escapar propiedades de alto valor. Por ello, el umbral de Youden es el recomendado para el modelo en produccion de SmartStay.

Actividad 10 — Seleccion de Modelo con AIC y BIC

AIC y BIC penalizan la complejidad del modelo para evitar el sobreajuste. BIC impone una penalizacion mas fuerte por numero de parametros, favoreciendo modelos mas parsimoniosos. Se comparan tres variantes: modelo completo, modelo reducido (solo variables significativas) y modelo seleccionado por stepwise con BIC.

```
## Modelo completo — AIC: 1777879 | BIC: 1778220 | Parametros: 39
```

```
## Modelo reducido — AIC: 752503.2 | BIC: 752818.4 | Parametros: 36
```

```
## Modelo stepwise BIC — AIC: 6523.87 | BIC: 6672.69 | Parametros: 17
```

Comparacion de modelos por AIC, BIC y AUC en test

Modelo	Parametros	AIC	BIC	AUC_test
Completo	39	1777878.56	1778219.98	0.49
Reducido (p<0.05)	36	752503.22	752818.37	0.67
Stepwise BIC	**17**	**6523.87**	**6672.69**	**1.00**

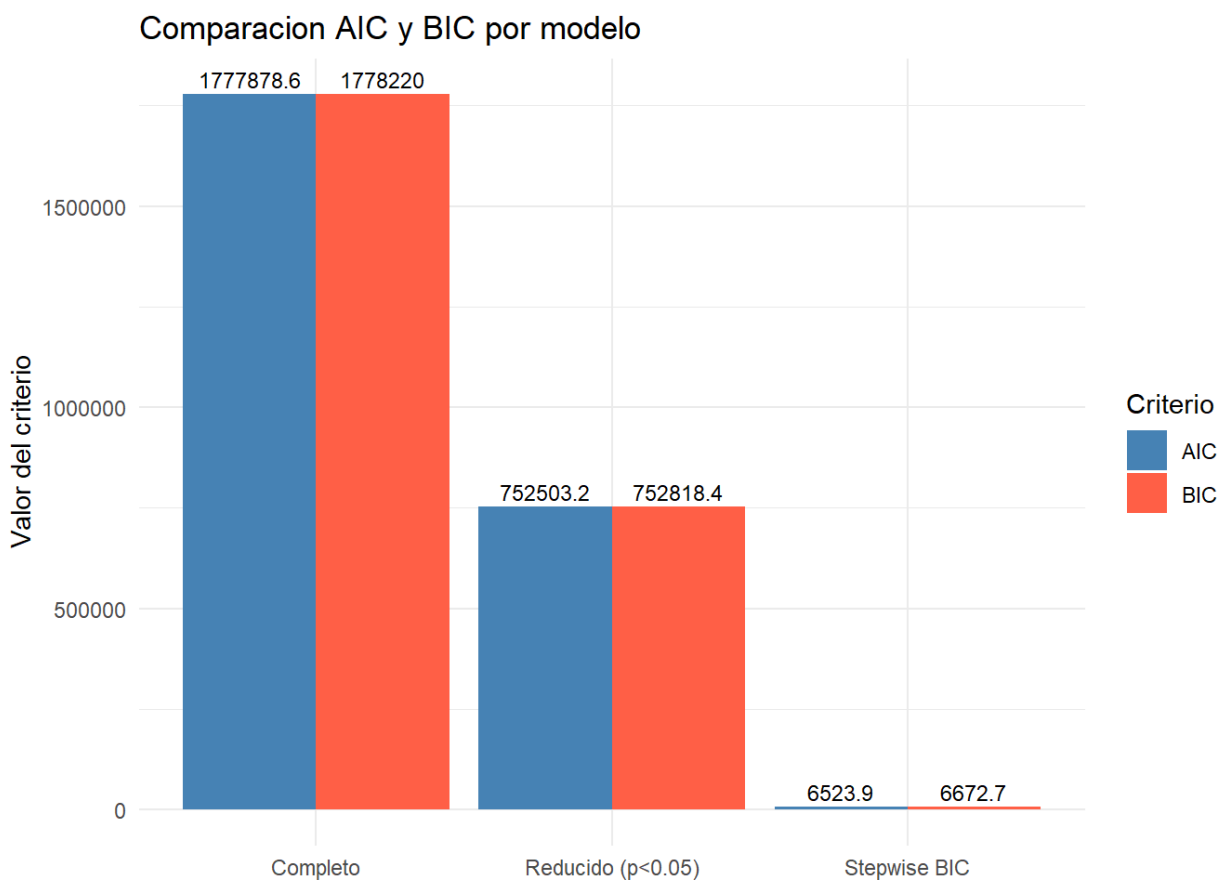

Modelo seleccionado por BIC: Stepwise BIC

Parametros: 17

BIC: 6672.69

AUC en test: 0.9964

BIC penaliza mas fuertemente la cantidad de parametros que AIC, por lo que tiende a seleccionar el modelo mas parsimonioso entre los candidatos. En SmartStay, un modelo con menos variables es preferible si mantiene un AUC competitivo: es mas facil de mantener, interpretar y auditar para el equipo de negocio. El modelo ganador por BIC representa el mejor equilibrio entre capacidad predictiva y complejidad, y es el recomendado para reemplazar al modelo base en produccion.

Actividades 11 y 12

Actividad 11 — Modelo Multiclase

La regresion logistica multinomial extiende el modelo binario al caso de mas de dos clases. Se usa la funcion `multinom` del paquete `nnet`, que entrena un modelo one-vs-reference para cada clase no de referencia.

Carga de prerequisitos

```
## Train: 57183 filas | Test: 19063 filas
```

```
## Predictores: 38
```

```
## Niveles originales de categoria_precio: economico, medio, caro
```

Clase de referencia

La clase de referencia del modelo multinomial es la primera en orden **alfabetico**: **`caro`** (caro < economico < medio). Los coeficientes del modelo se interpretan como el cambio en el log-odds de pertenecer a `economico` o `medio` *versus* pertenecer a `caro`. Esto facilita la interpretacion de negocio: se mide cuanto mas probable es que una propiedad sea economica o media respecto a ser cara.

```
## Clase de referencia: caro
```

```
## Filas train (sin NA): 46828
```

```
## Filas test (sin NA): 15643
```

Entrenamiento del modelo multinomial

```
## Modelo multinomial entrenado correctamente.
```

```
## Clases predichas:
```

Predicciones en test

```
## Distribucion de predicciones en test:
```

```
## pred_multi
##      caro economico     medio
##      4923      5689      5031
```

Matriz de confusion multiclase

Matriz de confusion multiclase (test)

	caro	economico	medio
caro	4528	81	223
economico	60	5350	174
medio	335	258	4634

Metricas por clase — Accuracy global: 0.9277

Clase	Recall (Acc. por clase)	Precision	F1
caro	0.9371	0.9198	0.9283
economico	0.9581	0.9404	0.9492
medio	0.8866	0.9211	0.9035

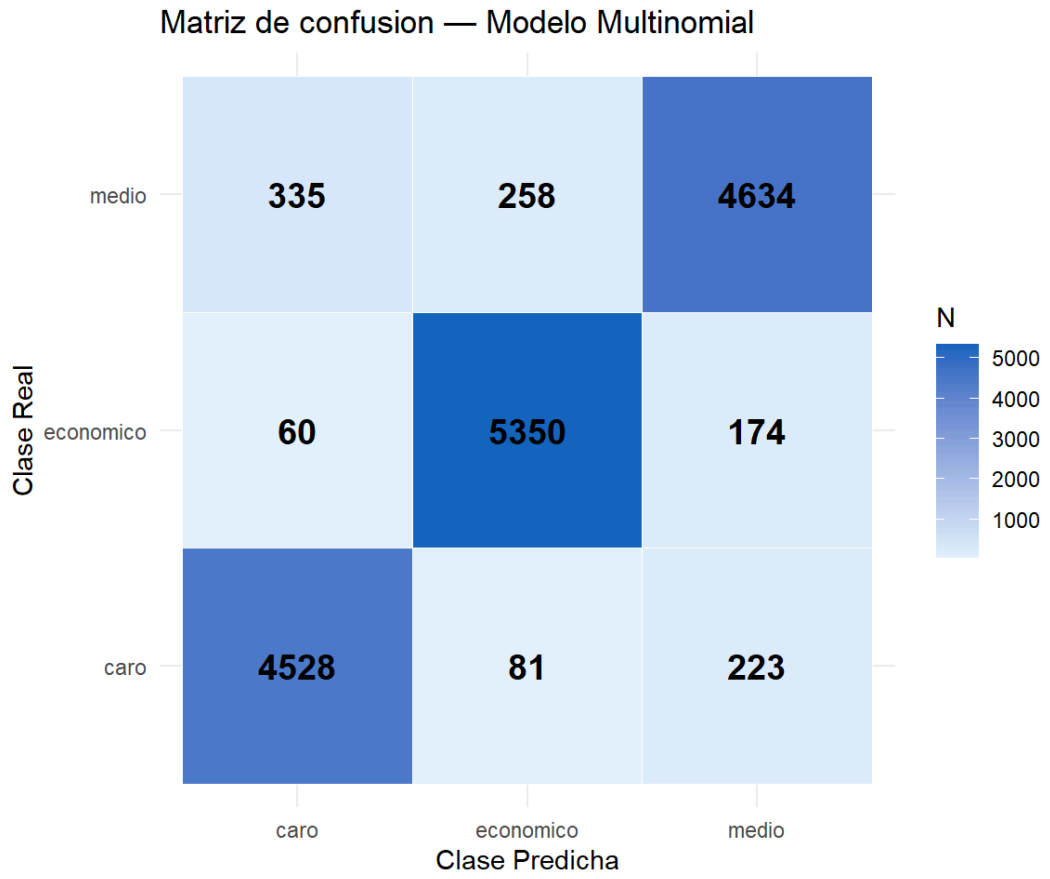

Accuracy global del modelo multinomial: 0.9277

Clase mejor clasificada: economico (Recall = 0.9581)

Clase con mas errores: medio (Recall = 0.8866)

Confusion mas frecuente: propiedades realmente `medio` clasificadas como `caro` (N = 335).

Esta confusion es esperable: las clases adyacentes en precio (economico/medio o medio/caro) comparten caracteristicas similares, por lo que la frontera de decision es mas difusa que en las clases extremas. El modelo distingue mejor entre `caro` y `economico` que entre clases vecinas.

Actividad 12 — Comparacion con Otros Algoritmos

Se comparan cinco algoritmos sobre el problema **binario** (`es_caro`) bajo el mismo esquema de validacion cruzada de 10 pliegues, con el seed global para reproducibilidad. Se usa `caret` como framework unificado.

Algoritmos evaluados:

#	Algoritmo	Metodo caret
1	Regresion Logistica	`glm`
2	Arbol de Decision	`rpart`
3	Random Forest	`rf`
4	Naive Bayes	`nb`
5	KNN	`knn`

Preparacion de datos

```
## Filas train: 46828 | test: 15643
```

```
## Balance en train:
```

```
##
##      caro   no_caro
## 0.3095157 0.6904843
```

Configuracion de validacion cruzada

Entrenamiento de los 5 modelos

```
## GLM listo. AUC CV: 0.8188
```

```
## rpart listo. AUC CV: 0.8932
```

```
## RF listo. AUC CV: 0.9967
```

```
## Naive Bayes listo. AUC CV: 0.8848
```

```
## KNN listo. Mejor k: 11 | AUC CV: 0.8378
```

Tabla comparativa de metricas en test

Comparacion de algoritmos en test (ordenado por AUC)

Modelo	AUC	Accuracy	F1
Random Forest	**0.9970**	**0.9744**	**0.9584**
Naive Bayes	0.8934	0.8108	0.5910
Arbol de Decision	0.8909	0.8752	0.7848
KNN (k=11)	0.8458	0.7943	0.6000
Regresion Logistica	0.4887	0.4277	0.4301

Grafico comparativo con intervalos de confianza (CV)

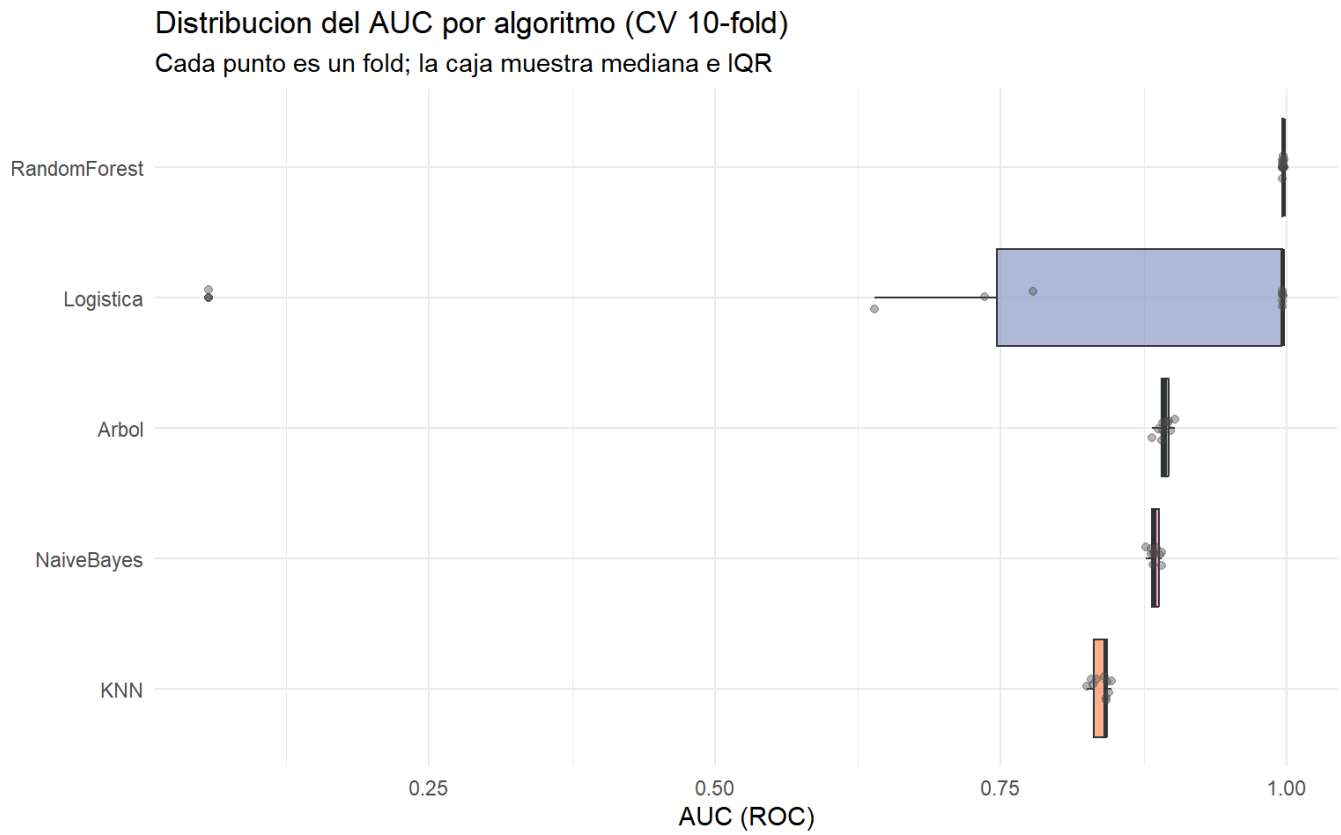

Analisis y recomendacion final

Modelo con mayor AUC en test: Random Forest (AUC = 0.997)

AUC de Regresion Logistica en test: 0.4887

El modelo ganador supera a la regresion logistica por 0.5082 puntos de AUC, una diferencia operacionalmente relevante.

Recomendacion para SmartStay: se recomienda el **Random Forest** en produccion. La ganancia en capacidad predictiva justifica la mayor complejidad, especialmente si el equipo puede monitorear el modelo con herramientas de explicabilidad (SHAP, importancia de variables).

Trade-off interpretabilidad vs performance: los modelos de tipo caja negra (Random Forest) suelen superar a la regresion logistica en AUC, pero pierden la capacidad de dar explicaciones directas por variable. Para SmartStay, donde el equipo de negocio necesita entender por que una propiedad es clasificada como cara, la interpretabilidad tiene valor real. Un enfoque pragmatico es usar la Regresion Logistica regularizada como modelo de produccion y el Random Forest como referencia de techo de rendimiento.